

Trích xuất Thông tin Hóa đơn Tiếng Việt từ Ảnh

Pipeline PaddleOCR – VietOCR – LayoutLMv3

Học viện Công nghệ Bưu chính Viễn thông
Khoa Công nghệ Thông tin 2

Tháng 6, 2026

Nội dung trình bày

- 1 Mở đầu
- 2 Tổng quan bài toán
- 3 Phân loại và tiến hóa
- 4 Trực giác và tư duy
- 5 Toán học hóa
- 6 Khoảng cách giữa lý thuyết và thực tế
- 7 Thách thức và rào cản
- 8 Kết luận

Bối cảnh bài toán

- Mỗi ngày, hàng triệu giao dịch thương mại tại Việt Nam tạo ra hàng triệu tờ hóa đơn giấy
- Kế toán viên gõ tay từng con số → sai sót nhập liệu thường xuyên
- Máy tính đã có thể đọc chữ in từ lâu, nhưng đọc hóa đơn thực tế vẫn là thách thức:
 - Font chữ tùy ý, góc chụp nghiêng
 - Ánh sáng không đều
 - Tiếng Việt với đầy đủ dấu thanh
- Cần biến **ảnh hóa đơn** thành **dữ liệu có cấu trúc**

Các tình huống thực tế

Kịch bản A – Kế toán doanh nghiệp nhỏ

300 hóa đơn công tác phí, mất 2–3 ngày nhập thủ công

Kịch bản B – Ứng dụng chi tiêu cá nhân


Chụp ảnh hóa đơn → tự động điền ngày, siêu thị, tổng tiền

Kịch bản C – Kiểm toán & tuân thủ thuế

Xác minh hàng nghìn hóa đơn VAT tự động

⇒ Nhu cầu chung: **Document Information Extraction (DIE)**

Mô hình hóa bài toán – Ba tầng xử lý



Đầu vào & Đầu ra


Đầu vào

Ảnh JPEG/PNG hóa đơn chụp bằng điện thoại (ngiêng, nhòe, ánh sáng không đều)

Đầu ra: Cấu trúc JSON có ngữ nghĩa

```
{ store_name: Circle K, date: 2024-05-27, total: 87000,  
  items: [ {name: Cafe sua da, qty: 2, price: 29000}, ... ] }
```

Pipeline xử lý



Text Detection – Từ sliding window đến anchor-free

Thế hệ 1 (trước 2015)

- MSER, SWT
- Phân tích pixel theo màu sắc, độ rộng nét bút
- Chỉ hoạt động với ảnh sạch, chữ đứng

Thế hệ 2 (2015–2017)

- CTPN, TextBoxes++, SegLink
- CNN-based với Anchor Boxes
- Khó phát hiện văn bản cong

Thế hệ 3 (2018–nay)

- **DB (Differentiable Binarization)**
- Xương sống của PaddleOCR
- Dự đoán probability map per pixel
- Ngưỡng có thể học được (differentiable threshold)
- Tối ưu cho CPU/mobile

Text Recognition – Từ template matching đến Attention

Thế hệ 1 (trước 2014)

- Tesseract v3, template matching
- Tách từng ký tự, so sánh template
- Yêu cầu font rõ ràng

Thế hệ 2 (2015–2018)

- **CRNN + CTC**
- CNN + BiLSTM + CTC loss
- Nền tảng OCR hiện đại

Thế hệ 3 (2018–nay)

- **VietOCR – Seq2Seq + Attention**
- VGG/ResNet encoder + Transformer decoder
- Xử lý dấu thanh tiếng Việt tốt hơn
- Pretrain trên 5M+ ảnh text tiếng Việt
- 60+ font chữ thông dụng

Key Information Extraction – Từ rule-based đến Multi-modal

Thế hệ 1 – Rule-based

- Regex, heuristic
- Nhanh, không cần training
- Vỡ ngay khi gặp format mới

Thế hệ 2 – BERT NER

- Token classification
- Bỏ qua thông tin vị trí không gian

Thế hệ 3 – LayoutLMv3

- Microsoft, 2022
- Kết hợp 3 nguồn: text OCR + tọa độ bbox + patch ảnh
- Unified self-attention qua cả 3 modality
- Pre-training: MLM + MIM + Text-Image Alignment
- **Đột phá** cho Document AI

Con người đọc hóa đơn như thế nào?

- **Vị trí không gian mang ngữ nghĩa:**
 - “Tổng cộng” → góc dưới phải, font lớn, in đậm
 - Tên cửa hàng → trên cùng, canh giữa
- **Căn lề là thông tin:**
 - Giá tiền căn phải, tên mặt hàng căn trái
- **Gần nhau → liên quan:**
 - “2 x 29,000” và “58,000” cùng dòng → cùng mặt hàng
- **Pattern lặp lại trong vùng bảng:**
 - 5 dòng có cấu trúc [tên | số | số] → bảng mặt hàng

Mô hình mô phỏng trực giác con người

Trực giác	Mô hình mô phỏng
Vùng chữ có cấu trúc pixel đặc biệt	PaddleOCR Detection: học probability map
Đọc ký tự cần ngữ cảnh xung quanh	VietOCR: attention “nhìn lại” toàn bộ ảnh
Vị trí + nội dung + hình ảnh cùng quyết định	LayoutLMv3: fuse 3 luồng trong transformer

Giả định ngầm

Mỗi mô hình đều có giả định riêng về dữ liệu input → khi giả định vi phạm, mô hình suy giảm chất lượng.

PaddleOCR – DB (Differentiable Binarization)

Phép toán chủ đạo: Segmentation + Adaptive Thresholding

Mô hình học 2 map song song từ feature map F :

$$P = \sigma(\text{Conv}(F))$$

← Probability map

$$T = \sigma(\text{Conv}'(F))$$

← Threshold map

$$\hat{B} = \sigma\left(\frac{P - T}{k}\right)$$

← Binary map (differentiable)

Bí quyết: $\sigma\left(\frac{P-T}{k}\right)$ với $k = 50$ xấp xỉ hàm step nhưng vẫn có gradient để backprop.

Loss: $L = L_{\text{bce}}(P, G_p) + \alpha \cdot L_{\text{bce}}(\hat{B}, G_b) + \beta \cdot L_1(T, G_t)$

Tham số: ResNet-18/50 + FPN, khoảng 10–27M tham số.

VietOCR – Seq2Seq với Attention

Phép toán chủ đạo: Cross-Attention trong Transformer decoder

$$\begin{aligned} F &= \text{CNN_Encoder}(\text{ảnh}) \quad \text{shape: } (H/4, W/4, C) \\ F_{\text{flat}} &= \text{reshape}(F) + \text{positional_embed} \quad \text{shape: } (S, C) \\ h_t &= \text{TransformerDecoder}(h_{t-1}, F_{\text{flat}}) \\ p(y_t) &= \text{Softmax}(\text{Linear}(h_t)) \end{aligned}$$

Attention: $\alpha_{t,s} = \text{softmax} \left(\frac{Q_t \cdot K_s}{\sqrt{d_k}} \right)$ – cho phép “nhìn” vào vùng feature tương ứng.

Đặc biệt tiếng Việt

Khi sinh “ề”, decoder attend mạnh vào vùng có dấu phụ kép (mũ + huyền).

Vocab: 120, 150 ký tự Unicode tiếng Việt + dấu câu + số

LayoutLMv3 – Multi-modal Transformer

Phép toán chủ đạo: Unified Self-Attention qua cả 3 modality

Input token i :

$$e_i = E_{\text{text}}(\text{token}_i) + E_{1D}(\text{pos}_i) + E_{2D}(x_1, y_1, x_2, y_2, w, h)$$

Image patch j :

$$v_j = \text{LinearProj}(\text{patch}_j) + E_{\text{img_pos}}(j)$$

Concatenate $\rightarrow$ Transformer $\rightarrow$ Contextualized representations

Pre-training objectives:

- Masked Language Modeling (MLM) trên text
- Masked Image Modeling (MIM) trên ảnh
- Text-Image Alignment

Hàm mất mát và lý do lựa chọn

Tầng	Loss Function	Tại sao?
Detection	BCE + L1	Gradient ổn định, robust với outlier
Recognition	Cross-Entropy chuỗi	Smooth, vi phân được
KIE	Cross-Entropy/token	Tính được tại từng token

Tại sao không dùng Metric làm Loss?

- Field Exact Match: không có gradient
- CER (edit distance): không liên tục
- Entity F1: phụ thuộc ngưỡng confidence

⇒ Dùng CE làm Loss, F1/CER/Exact Match chỉ để đánh giá.

Điểm đau lớn nhất

Mô hình có thể đạt **CER rất thấp (98% ký tự đúng)** nhưng **Field Exact Match chỉ 70%** – vì chỉ cần sai 1 ký tự trong “87.000” thành “87.500” là cả trường total sai hoàn toàn.

Khả năng mở rộng Loss:

- Thêm class mới: DISCOUNT, TAX_CODE
- Weighted loss: ưu tiên TOTAL, DATE
- Consistency constraint: $\sum(\text{subtotals}) \approx \text{total}$

Trở ngại đã giải quyết & còn tồn đọng

Đã giải quyết

- Văn bản đa hướng, cong → DB, ABCNet (bezier curves)
- Font chữ đa dạng tiếng Việt → VietOCR pretrained + augmentation
- Hiểu layout cơ bản → 2D positional embedding (LayoutLM)

Còn tồn đọng

- × Ảnh chất lượng thấp (run, nhòe, phản chiếu) – CER tụt 85–90%
- × Hóa đơn in nhiệt bị phai – contrast rất thấp
- × Zero-shot generalization – cần fine-tune cho mỗi template mới
- × Dữ liệu tiếng Việt khan hiếm, hạ tầng GPU đắt
- × Relation Extraction phức tạp (20+ mặt hàng)

Hướng đi tương lai

- **End-to-end Document Understanding:**
 - Donut, Nougat – bỏ qua OCR, ảnh → JSON trực tiếp
- **Large Vision-Language Models (LVLMs):**
 - GPT-4V, Gemini – zero-shot, không cần fine-tune
- **Self-supervised pretraining trên tài liệu Việt:**
 - Corpus hóa đơn/biểu mẫu tiếng Việt quy mô lớn
- **Synthetic data generation:**
 - Tạo hóa đơn giả + domain randomization

- Bài toán trích xuất hóa đơn tiếng Việt đòi hỏi giải quyết đồng thời 3 thách thức: **phát hiện vùng chữ, nhận dạng ký tự, hiểu cấu trúc ngữ nghĩa**
- Pipeline **PaddleOCR** → **VietOCR** → **LayoutLMv3** là lựa chọn hợp lý hiện tại với pretrained weights chất lượng tốt
- Nhược điểm cố hữu: **lỗi tích lũy qua từng tầng**
- Ranh giới giữa OCR+NLP pipeline và end-to-end LVLM đang dần mờ đi

Cảm ơn Thầy và Các bạn!

Xin cảm ơn!

Học viện Công nghệ Bưu chính Viễn thông
Khoa Công nghệ Thông tin 2